

# Einführung in die künstliche Intelligenz EKI02 – ML Klassifikation

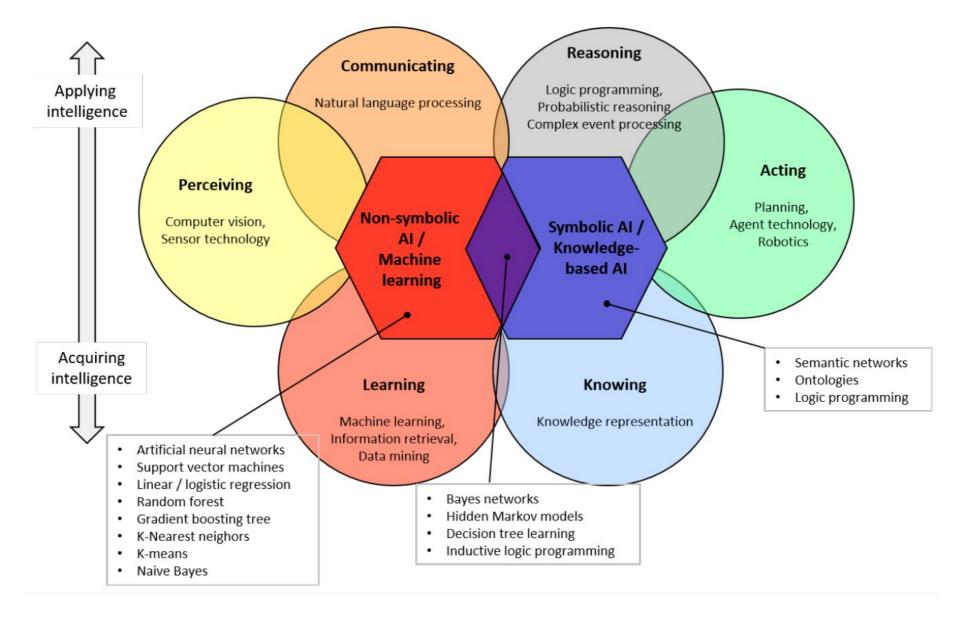
Prof. Dr. A. del Pino



Bild: https://en.wikipedia.org/wiki/Machine\_learning#/media/File:Anatomy-1751201\_1280.png

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

#### Die KI-Landkarte



Bildquelle: B. Humm "Applied Artificial Intelligence", S. 4

## Was ist Machine Learning (maschinelles Lernen)?

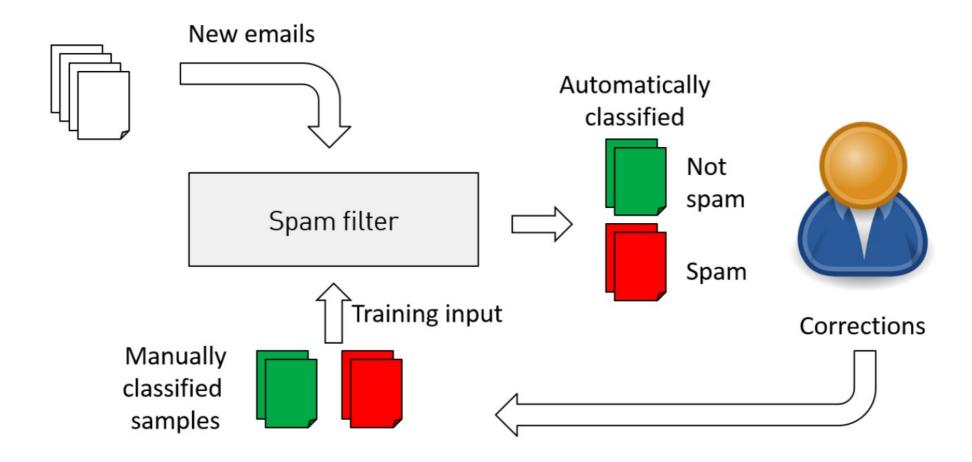
Erzeugen eines Modells, basierend auf Eingaben ("Training") und die Nutzung des Modells für Vorhersagen ("produktive Anwendung").

Das Modell wird also nicht explizit programmiert !!!

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

## ML Anwendungen: Spam Filtering

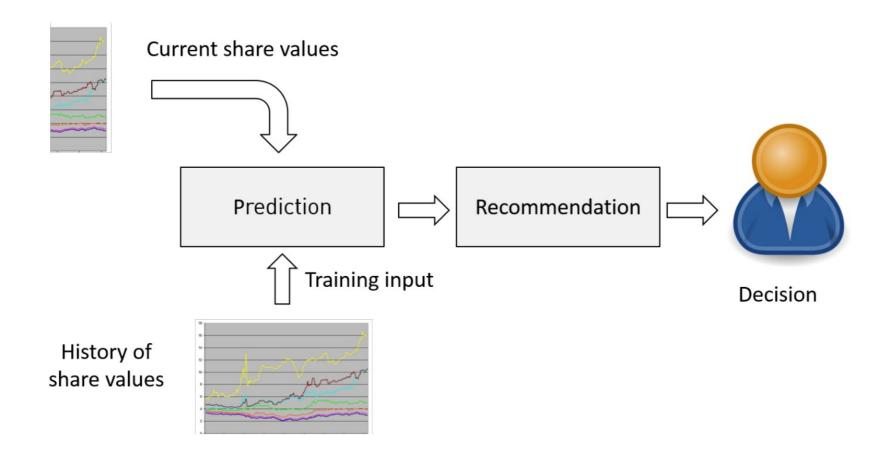
Aufgabe: Klassifiziere neue E-Mails danach, ob sie Spam oder nicht Spam sind



Bildquelle: B. Humm "Applied Artificial Intelligence", S. 13

## ML Anwendungen: Wertpapierhandel

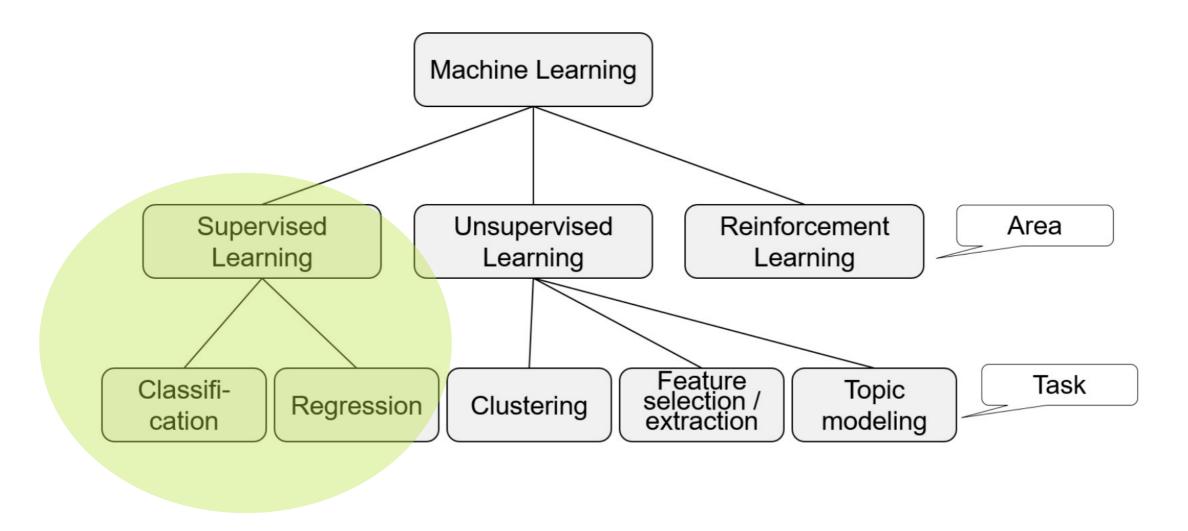
Aufgabe: Mache Empfehlungen, welche Aktien gekauft bzw. verkauft werden sollen



Bildquelle: B. Humm "Applied Artificial Intelligence", S. 14

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

## Kategorien von ML Aufgaben



Bildquelle: B. Humm "Applied Artificial Intelligence", S. 15

## Aufgaben des Supervised Learning (Überwachtes Lernen)

### Klassifikation

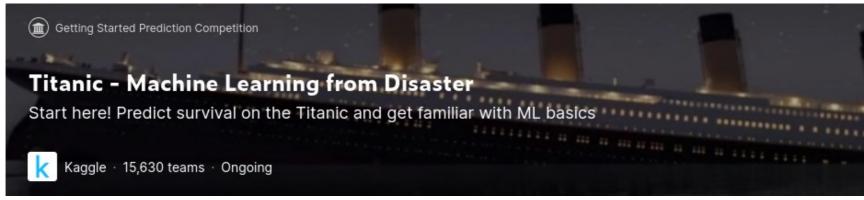
- Gegeben: Datensätze als Eingabe für das Training, welche in zwei oder mehrere Klassen ("Kategorien") eingeteilt sind.
- Ziel: Ein Modell erzeugen, welches neue, bisher unbekannte Datensätze klassifizieren kann.
- Beispiele: Spam-Filter, Fraud-Detection,...

## Regression

- Gegeben: Datensätze als Eingabe für das Training, welche einen numerischen Ausgabewert besitzen.
- Ziel: Ein Modell erzeugen, welches für neue, bisher unbekannte Datensätze den Ausgabewert vorhersagen kann.
- Beispiel: Aktienkurs-Vorhersage

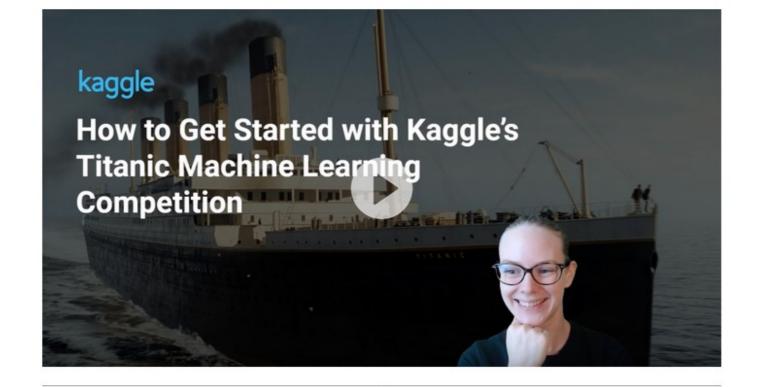
- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

## Beispiel: Klassifikation der Überlebenden der Titanic



Bildquelle: https://www.kaggle.com/competitions/titanic

- "Hello World"-Beispiel für ML
- Viele Tutorials online verfügbar, z.B. https://www.kaggle.com/code/alexisbcook/titanic-tutorial
- Eingabe: Informationen ("Features") über die Passagiere, z.B. Alter, Geschlecht,...
- Ausgabe: Klassifikation nach zwei Kategorien: Überlebt bzw. Gestorben



#### The Challenge

The sinking of the Titanic is one of the most infamous shipwrecks in history.

On April 15, 1912, during her maiden voyage, the widely considered "unsinkable" RMS Titanic sank after colliding with an iceberg. Unfortunately, there weren't enough lifeboats for everyone onboard, resulting in the death of 1502 out of 2224 passengers and crew.

While there was some element of luck involved in surviving, it seems some groups of people were more likely to survive than others.

In this challenge, we ask you to build a predictive model that answers the question: "what sorts of people were more likely to survive?" using passenger data (ie name, age, gender, socio-economic class, etc).

Quelle: https://www.kaggle.com/competitions/titanic

## Was gefällt mir nicht an dem Titanic Beispiel

• Es ist kein realistisches ML-Beispiel, aber warum ?

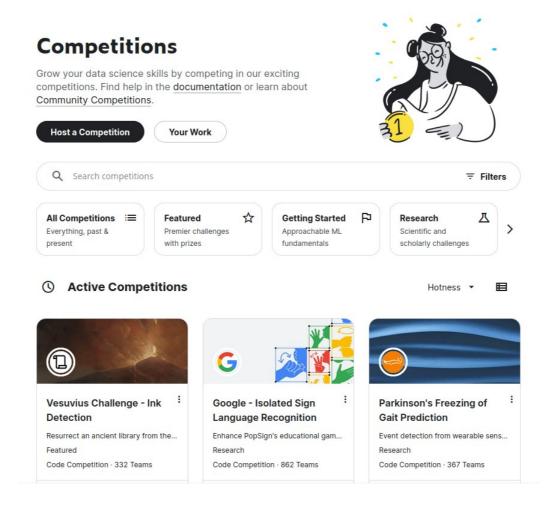


Bildquelle: https://cdn.pixabay.com/photo/2015/11/03/08/56/question-mark-1019820\_960\_720.jpg

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

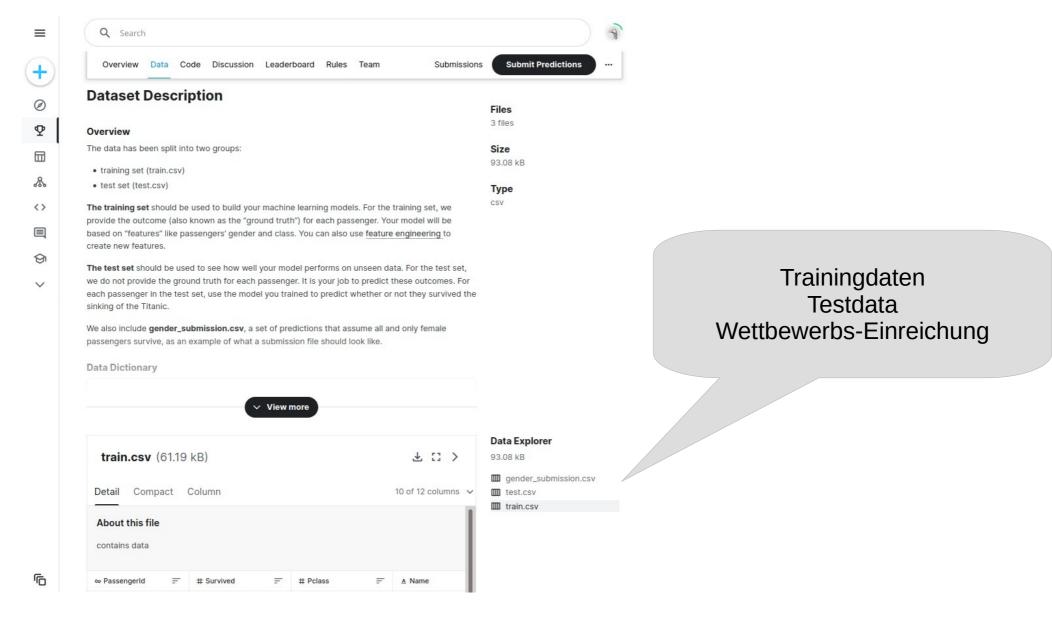
## Kaggle: Eine Community mit Datensätzen, Wettbewerben etc...





Quelle: https://www.kaggle.com

## Daten von Kaggle herunterladen



Quelle: https://www.kaggle.com/competitions/titanic/data?select=train.csv

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

#### Attribute des Titanic-Datensatzes

#### Features (ML Eingabe)

Eindeutige Passagier-ID, nicht benutzt für die Klassifikation

Passagierklasse 1 = Erste Klasse 3 = Dritte Klasse Alter in Jahren Anzahl Anzahl
siblings Eltern +
+ Kinder
spouse

Ticket nummer Einstiegshafen
C=Cherbourg
S=Southhampton
Q=Queenstown

NaN =

Werte

fehlende

	Passengerld	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
689	690	1	1	Madill, Miss. Georgette Alexandra	female	15.0	0	1	24160	211.3375	B5	S
525	526	0	3	Farrell, Mr. James	male	40.5	0	0	367232	7.7500	NaN	Q
278	279	0	3	Rice, Master. Eric	male	7.0	4	1	382652	29.1250	NaN	Q

Label, Ziel der

Klassifikation

0 = Gestorben

1 = Überlebt

Label (ML Ausgabe)

Quelle: https://www.kaggle.com/code/gunesevitan/titanic-advanced-feature-engineering-tutorial

h\_da

HOCHSCHULE DARMSTADT UNIVERSITY OF APPLIED SCIENCES

## Attribute des Titanic-Datensatzes (2)

	Passengerld	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
689	690	1	1	Madill, Miss. Georgette Alexandra	female	15.0	0	1	24160	211.3375	B5	S
525	526	0	3	Farrell, Mr. James	male	40.5	0	0	367232	7.7500	NaN	Q
278	279	0	3	Rice, Master. Eric	male	7.0	4	1	382652	29.1250	NaN	Q

Kategorie	Kategoris ch, binär	Kategori sch, ordinal	Text	Kategor isch	Num erisc h	Numer isch	Numeri sch	Text	Numerisch	Text	Kategorisch
Datentyp	int	int	string	string	float	int	int	int	float	string	string
Fehlende Daten ?	nein	nein	nein	nein	ja	nein	nein	nein	ja	ja	ja

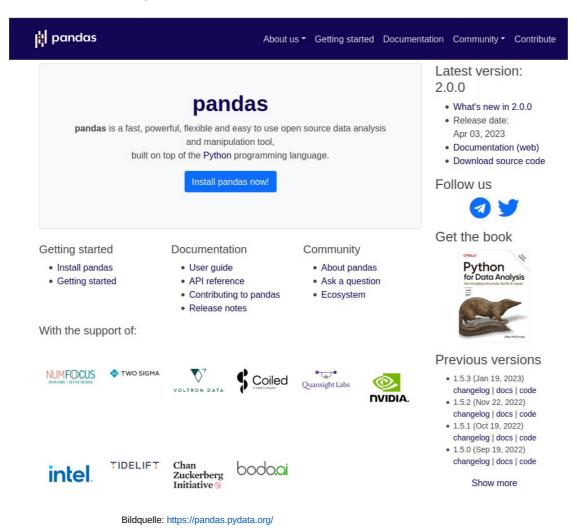
Quelle: https://www.kaggle.com/code/gunesevitan/titanic-advanced-feature-engineering-tutorial

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

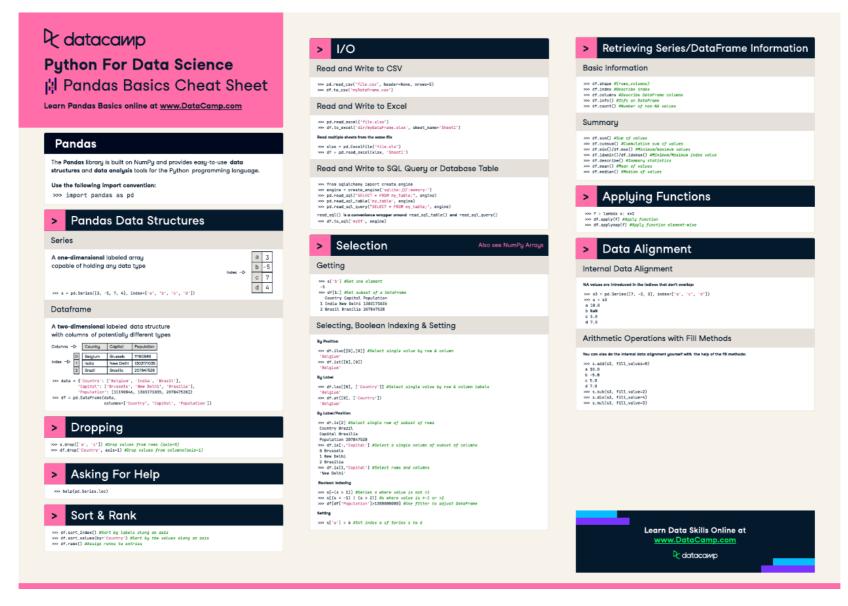
## Das Datenanalyse-Paket pandas

pip install pandas

python3 -m pip install --user pandas



#### **Pandas Basics Cheat Sheet**



Bildquelle:https://www.datacamp.com/cheat-sheet/pandas-cheat-sheet-for-data-science-in-python

### DataFrame aus einer CSV-Datei laden

Liest eine CSV-Datei (relativer Pfad zum Notebook) und speichert es in einem pd.DataFrame. Viele optionale Parameter z.B. encoding, delimiter, quotechar,...

import pandas as pd

```
train_data = pd.read_csv('data/train.csv')
test_data = pd.read_csv('data/test.csv')
```

Quelle: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.read\_csv.html

## pd.DataFrame, die primäre pandas Datenstruktur

### pandas.DataFrame

class pandas.DataFrame(data=None, index=None, columns=None, dtype=None, copy=None)

Two-dimensional, size-mutable, potentially heterogeneous tabular data.

[source]

Data structure also contains labeled axes (rows and columns). Arithmetic operations align on both row and column labels. Can be thought of as a dict-like container for Series objects. The primary pandas data structure.

#### Parameters: data: ndarray (structured or homogeneous), Iterable, dict, or DataFrame

Dict can contain Series, arrays, constants, dataclass or list-like objects. If data is a dict, column order follows insertion-order. If a dict contains Series which have an index defined, it is aligned by its index. This alignment also occurs if data is a Series or a DataFrame itself. Alignment is done on Series/DataFrame inputs.

If data is a list of dicts, column order follows insertion-order.

#### index: Index or array-like

Index to use for resulting frame. Will default to RangeIndex if no indexing information part of input data and no index provided.

#### columns: Index or array-like

Column labels to use for resulting frame when data does not have them, defaulting to RangeIndex(0, 1, 2, ..., n). If data contains column labels, will perform column selection instead.

#### dtype: dtype, default None

Data type to force. Only a single dtype is allowed. If None, infer.

#### copy: bool or None, default None

Copy data from inputs. For dict data, the default of None behaves like <a href="copy=True">copy=True</a>. For DataFrame or 2d ndarray input, the default of None behaves like <a href="copy=False">copy=False</a>. If data is a dict containing one or more Series (possibly of different dtypes), <a href="copy=False">copy=False</a> will ensure that these inputs are not copied.

Quelle: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.html

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

## Datenvorverarbeitung: Extrahieren der relevanten Spalten

Spalten aus einem Datensatz extrahieren Ein Spaltenname → Vektor Liste von Spaltennamen → Matrix

```
# Labels extrahieren
y = train_data ["Survived"]

# Relevante Spalten (features) extrahieren (wird später vielleicht erweitert)
features = ["Pclass", "Sex", "SibSp", "Parch"]
X = train_data [features]
```

Namenskonventionen aus der Mathematik Matrix: Großbuchstaben, z.B. X Vektor: Kleinbuchstaben, z.B. y

Input: x (oder X)
Ouput y (oder Y)

## Datenvorverarbeitung: Fehlende Werte auffüllen

```
# Fehlende Werte (n/a values) mit einem bestimmten Wert auffüllen
data['Embarked'] = data['Embarked'].fillna('S')
```

DataFrame.fillna liefert einen modifizierten DataFame zurück (der Original-DataFrame wird nicht verändert). Daher die Zuweisung, um ihn zu überschreiben

```
import numpy as np
from sklearn.impute import SimpleImputer

imp = SimpleImputer(missing_values=np.nan, strategy='mean')
data['Age'] = imp.fit_transform(data[['Age']])
```

# Fehlende Werte mit dem Mittelwert aller Werte auffüllen

Quellen: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.fillna.htm https://scikit-learn.org/stable/modules/generated/sklearn.impute.SimpleImputer.html

SimpleImputer kennt verschiedene Strategien, um fehlende Werte aufzufüllen

## Scientific Computing Paket NumPy



The fundamental package for scientific computing with Python



#### Meet the new NumPy docs team leads

#### POWERFUL N-DIMENSIONAL ARRAYS

Fast and versatile, the NumPy vectorization, indexing, and broadcasting concepts are the defacto standards of array computing today.

#### NUMERICAL COMPUTING TOOLS

NumPy offers comprehensive mathematical functions, random number generators, linear algebra routines, Fourier transforms, and more.

#### **OPEN SOURCE**

Distributed under a liberal BSD license, NumPy is developed and maintained publicly on GitHub by a vibrant, responsive, and diverse community.

#### INTEROPERABLE

NumPy supports a wide range of hardware and computing platforms, and plays well with distributed, GPU, and sparse array libraries.

#### PERFORMANT

The core of NumPy is well-optimized C code. Enjoy the flexibility of Python with the speed of compiled code.

#### **EASY TO USE**

NumPy's high level syntax makes it accessible and productive for programmers from any background or experience level.

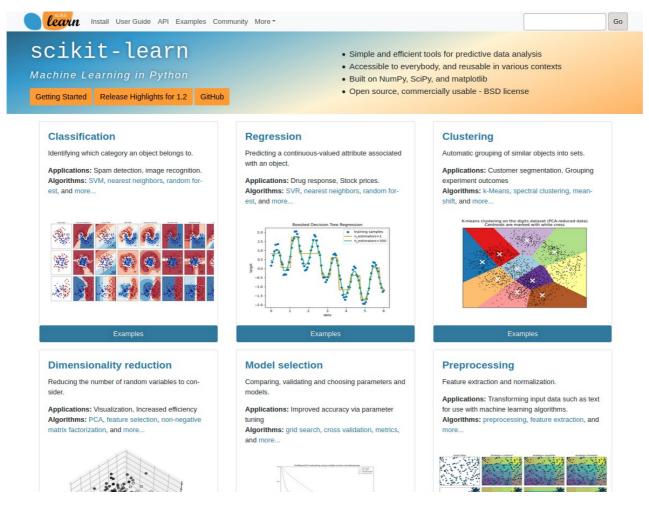
Quelle:https://numpy.org/

HOCHSCHULE DARMSTADT UNIVERSITY OF APPLIED SCIENCES

#### ML Paket: scikit-learn

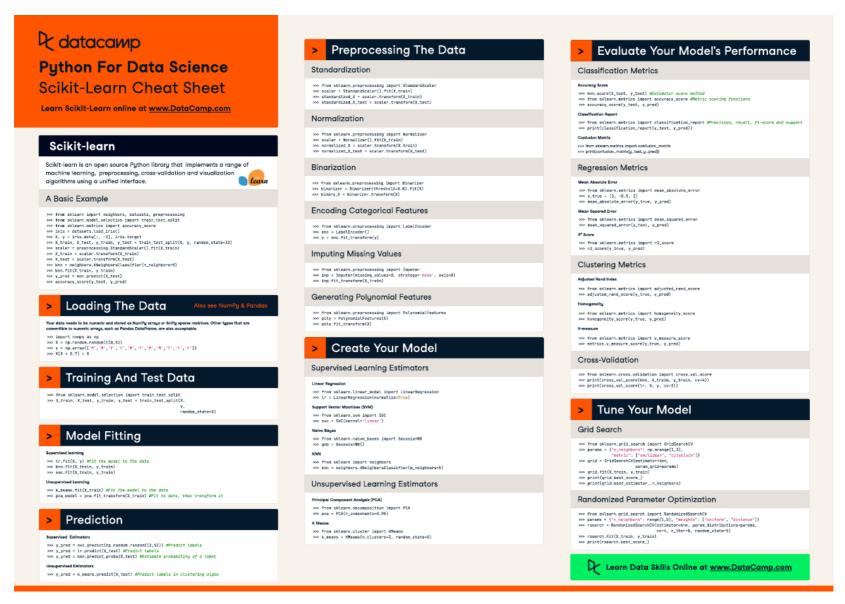
pip install scikit-learn

python3 -m pip install --user scikit-learn



Bildquelle:https://scikit-learn.org/stable/

#### scikit-learn cheat sheet



Quelle: https://www.datacamp.com/cheat-sheet/scikit-learn-cheat-sheet-python-machine-learning

## Weitere Ideen für die Vorverarbeitung der Daten ?



Bildquelle: https://cdn.pixabay.com/photo/2015/11/03/08/56/question-mark-1019820\_960\_720.jpg

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

## ML Training

Ausgewählter Ansatz zum ML: DecisionTreeClassifier

```
# ML Modell erzeugen
```

model = DecisionTreeClassifier ()

# ML Modell trainieren

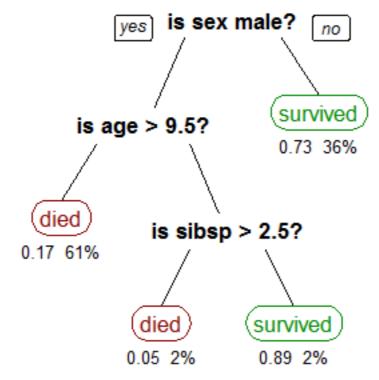
model.fit (X, y)

Trainieren ("fitting") des Modells mit den Features (X) und den Labels (y)

Quelle:https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.htm

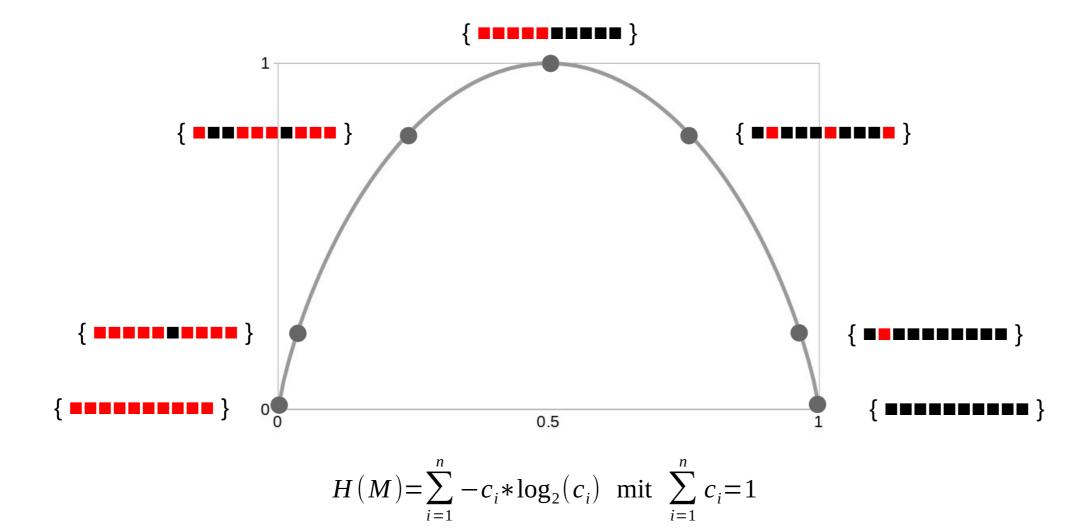
## Lernen mit einem Entscheidungsbaum

- Entscheidungsbaum: Ein Baum mit den Klassen als Blättern (hier: überlebt, gestorben). Die Entscheidungen sind in den inneren Knoten (z.B. männlich?) und die Werte an den Kanten des Baums (z.B. Ja, Nein).
- Der Learnvorgang: Automatisch einen Entscheidungsbaum aus den Trainingsdaten (features und Labels) aufbauen.
- Beispiel: Entscheidungsbaum für die Klassifikation der Überlebenden der Titanic



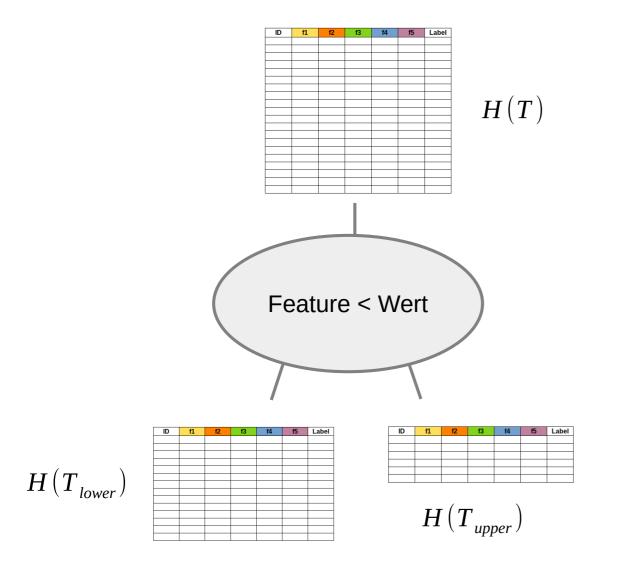
Bildquelle: https://commons.wikimedia.org/wiki/File:CART\_tree\_titanic\_survivors.png

## Aufbauen eines Entscheidungsbaums - Entropie



$$H(\{ = = = = = = \}) = -3/10 * log_2(3/10) -7/10 * log_2(7/10) = 0.881$$

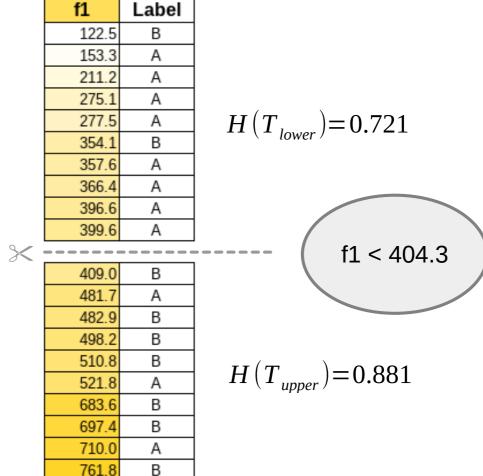
### Aufbauen eines Entscheidungsbaums – Entropieverlust



Wähle Feature und Wert so, dass ein möglichst großer Entropieverlust entsteht.

$$H\left(T\right) - \frac{\left|T_{lower}\right|}{\left|T\right|} * H\left(T_{lower}\right) - \frac{\left|T_{upper}\right|}{\left|T\right|} * H\left(T_{upper}\right)$$

ID	f1	f2	f3	f4	f5	Label
1	354.1	15.0	0.73	802.3	347.0	В
2	366.4	28.9	0.99	153.7	348.5	Α
3	697.4	31.8	0.83	9.8	852.0	В
4	521.8	36.1	0.87	343.9	1195.2	Α
5	482.9	22.1	0.31	159.9	1106.9	В
6	510.8	7.1	0.05	663.1	58.7	В
7	710.0	38.4	0.52	861.4	812.9	Α
8	275.1	36.2	0.12	841.7	409.4	Α
9	122.5	7.5	0.91	111.5	756.4	В
10	357.6	16.2	0.28	815.9	664.4	Α
11	761.8	2.4	0.62	658.3	11.0	В
12	498.2	33.3	0.81	125.7	512.2	В
13	683.6	11.9	0.56	608.2	1640.3	В
14	481.7	4.1	0.95	756.6	253.8	Α
15	153.3	1.6	0.58	502.2	65.2	Α
16	399.6	37.2	0.94	894.0	741.4	Α
17	396.6	38.7	0.72	886.1	1203.5	Α
18	211.2	28.0	0.04	124.2	462.5	Α
19	409.0	25.6	0.20	144.1	990.3	В
20	277.5	14.8	0.83	935.4	103.4	Α



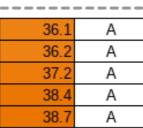
$$H(T) = 0.992$$

$$H(T) - \frac{10}{20} * H(t_{lower}) - \frac{10}{20} * H(T_{upper}) = 0.191$$

ID	f1	f2	f3	f4	f5	Label
1	354.1	15.0	0.73	802.3	347.0	В
2	366.4	28.9	0.99	153.7	348.5	Α
3	697.4	31.8	0.83	9.8	852.0	В
4	521.8	36.1	0.87	343.9	1195.2	Α
5	482.9	22.1	0.31	159.9	1106.9	В
6	510.8	7.1	0.05	663.1	58.7	В
7	710.0	38.4	0.52	861.4	812.9	Α
8	275.1	36.2	0.12	841.7	409.4	Α
9	122.5	7.5	0.91	111.5	756.4	В
10	357.6	16.2	0.28	815.9	664.4	Α
11	761.8	2.4	0.62	658.3	11.0	В
12	498.2	33.3	0.81	125.7	512.2	В
13	683.6	11.9	0.56	608.2	1640.3	В
14	481.7	4.1	0.95	756.6	253.8	Α
15	153.3	1.6	0.58	502.2	65.2	Α
16	399.6	37.2	0.94	894.0	741.4	Α
17	396.6	38.7	0.72	886.1	1203.5	Α
18	211.2	28.0	0.04	124.2	462.5	Α
19	409.0	25.6	0.20	144.1	990.3	В
20	277.5	14.8	0.83	935.4	103.4	Α

	f2	Label	
	1.6	Α	
	2.4	В	
	4.1	Α	
	7.1	В	
	7.5	В	
	11.9	В	
	14.8	Α	
	15.0	В	
	16.2	Α	
	22.1	В	
	25.6	В	
	28.0	Α	
	28.9	Α	
	31.8	В	
	33.3	В	
<b>X</b>			
	36.1	Α	

$$H(T_{lower}) = 0.97$$

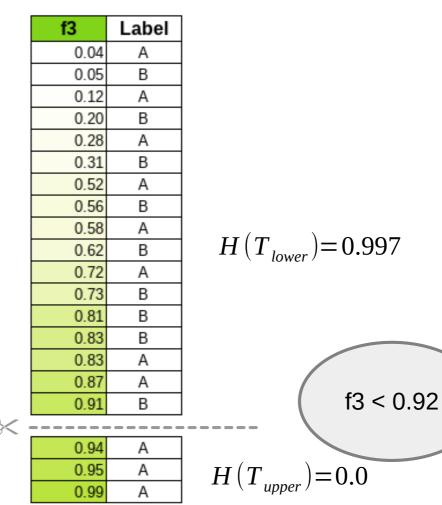


$$H(T_{upper}) = 0.0$$

$$H(T) = 0.992$$

$$H(T) - \frac{15}{20} * H(t_{lower}) - \frac{5}{20} * H(T_{upper}) = 0.264$$

ID	f1	f2	f3	f4	f5	Label
1	354.1	15.0	0.73	802.3	347.0	В
2	366.4	28.9	0.99	153.7	348.5	Α
3	697.4	31.8	0.83	9.8	852.0	В
4	521.8	36.1	0.87	343.9	1195.2	Α
5	482.9	22.1	0.31	159.9	1106.9	В
6	510.8	7.1	0.05	663.1	58.7	В
7	710.0	38.4	0.52	861.4	812.9	Α
8	275.1	36.2	0.12	841.7	409.4	Α
9	122.5	7.5	0.91	111.5	756.4	В
10	357.6	16.2	0.28	815.9	664.4	Α
11	761.8	2.4	0.62	658.3	11.0	В
12	498.2	33.3	0.81	125.7	512.2	В
13	683.6	11.9	0.56	608.2	1640.3	В
14	481.7	4.1	0.95	756.6	253.8	Α
15	153.3	1.6	0.58	502.2	65.2	Α
16	399.6	37.2	0.94	894.0	741.4	Α
17	396.6	38.7	0.72	886.1	1203.5	Α
18	211.2	28.0	0.04	124.2	462.5	Α
19	409.0	25.6	0.20	144.1	990.3	В
20	277.5	14.8	0.83	935.4	103.4	Α



$$H(T) = 0.992$$

$$H(T) - \frac{17}{20} * H(t_{lower}) - \frac{3}{20} * H(T_{upper}) = 0.144$$

ID	f1	f2	f3	f4	f5	Label
1	354.1	15.0	0.73	802.3	347.0	В
2	366.4	28.9	0.99	153.7	348.5	Α
3	697.4	31.8	0.83	9.8	852.0	В
4	521.8	36.1	0.87	343.9	1195.2	Α
5	482.9	22.1	0.31	159.9	1106.9	В
6	510.8	7.1	0.05	663.1	58.7	В
7	710.0	38.4	0.52	861.4	812.9	Α
8	275.1	36.2	0.12	841.7	409.4	Α
9	122.5	7.5	0.91	111.5	756.4	В
10	357.6	16.2	0.28	815.9	664.4	Α
11	761.8	2.4	0.62	658.3	11.0	В
12	498.2	33.3	0.81	125.7	512.2	В
13	683.6	11.9	0.56	608.2	1640.3	В
14	481.7	4.1	0.95	756.6	253.8	Α
15	153.3	1.6	0.58	502.2	65.2	Α
16	399.6	37.2	0.94	894.0	741.4	Α
17	396.6	38.7	0.72	886.1	1203.5	Α
18	211.2	28.0	0.04	124.2	462.5	Α
19	409.0	25.6	0.20	144.1	990.3	В
20	277.5	14.8	0.83	935.4	103.4	Α

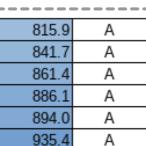
f4

9.8

Label

В

$$H(T_{lower}) = 0.94$$



$$H(T_{upper})=0.0$$

f4 < 809.1

$$H(T) = 0.992$$

$$H(T) - \frac{14}{20} * H(t_{lower}) - \frac{6}{20} * H(T_{upper}) = 0.334$$

ID	f1	f2	f3	f4	f5	Label
1	354.1	15.0	0.73	802.3	347.0	В
2	366.4	28.9	0.99	153.7	348.5	Α
3	697.4	31.8	0.83	9.8	852.0	В
4	521.8	36.1	0.87	343.9	1195.2	Α
5	482.9	22.1	0.31	159.9	1106.9	В
6	510.8	7.1	0.05	663.1	58.7	В
7	710.0	38.4	0.52	861.4	812.9	Α
8	275.1	36.2	0.12	841.7	409.4	Α
9	122.5	7.5	0.91	111.5	756.4	В
10	357.6	16.2	0.28	815.9	664.4	Α
11	761.8	2.4	0.62	658.3	11.0	В
12	498.2	33.3	0.81	125.7	512.2	В
13	683.6	11.9	0.56	608.2	1640.3	В
14	481.7	4.1	0.95	756.6	253.8	Α
15	153.3	1.6	0.58	502.2	65.2	Α
16	399.6	37.2	0.94	894.0	741.4	Α
17	396.6	38.7	0.72	886.1	1203.5	Α
18	211.2	28.0	0.04	124.2	462.5	Α
19	409.0	25.6	0.20	144.1	990.3	В
20	277.5	14.8	0.83	935.4	103.4	Α

	4E	Labal	$H(T_{lower}) = 0.0$
	f5	Label	$II(I_{lower}) = 0.0$
	11.0	В	
	58.7	В	
<			( F
	65.2	Α	
	103.4	Α	
	253.8	Α	
	347.0	В	
	348.5	Α	
	409.4	Α	
	462.5	Α	
	512.2	В	
	664.4	Α	
	741.4	Α	$H(T_{upper}) = 0.96$
	756.4	В	
	812.9	Α	
	852.0	В	
	990.3	В	
	1106.9	В	
	1195.2	Α	
	1203.5	Α	
	1640.3	В	

$$H(T_{upper})=0.964$$

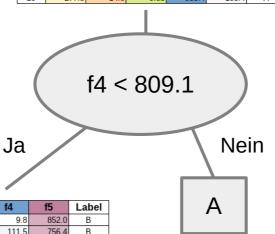
$$H(T) = 0.992$$

$$H(T) - \frac{2}{20} * H(t_{lower}) - \frac{18}{20} * H(T_{upper}) = 0.125$$

# Aufbauen eines Entscheidungsbaums – Zwischenergebnis

ID	f1	f2	f3	f4	f5	Label
1	354.1	15.0	0.73	802.3	347.0	В
2	366.4	28.9	0.99	153.7	348.5	Α
3	697.4	31.8	0.83	9.8	852.0	В
4	521.8	36.1	0.87	343.9	1195.2	Α
5	482.9	22.1	0.31	159.9	1106.9	В
6	510.8	7.1	0.05	663.1	58.7	В
7	710.0	38.4	0.52	861.4	812.9	Α
8	275.1	36.2	0.12	841.7	409.4	Α
9	122.5	7.5	0.91	111.5	756.4	В
10	357.6	16.2	0.28	815.9	664.4	Α
11	761.8	2.4	0.62	658.3	11.0	В
12	498.2	33.3	0.81	125.7	512.2	В
13	683.6	11.9	0.56	608.2	1640.3	В
14	481.7	4.1	0.95	756.6	253.8	Α
15	153.3	1.6	0.58	502.2	65.2	Α
16	399.6	37.2	0.94	894.0	741.4	Α
17	396.6	38.7	0.72	886.1	1203.5	Α
18	211.2	28.0	0.04	124.2	462.5	Α
19	409.0	25.6	0.20	144.1	990.3	В
20	277.5	14.8	0.83	935.4	103.4	Α

$$H(T) = 0.992$$



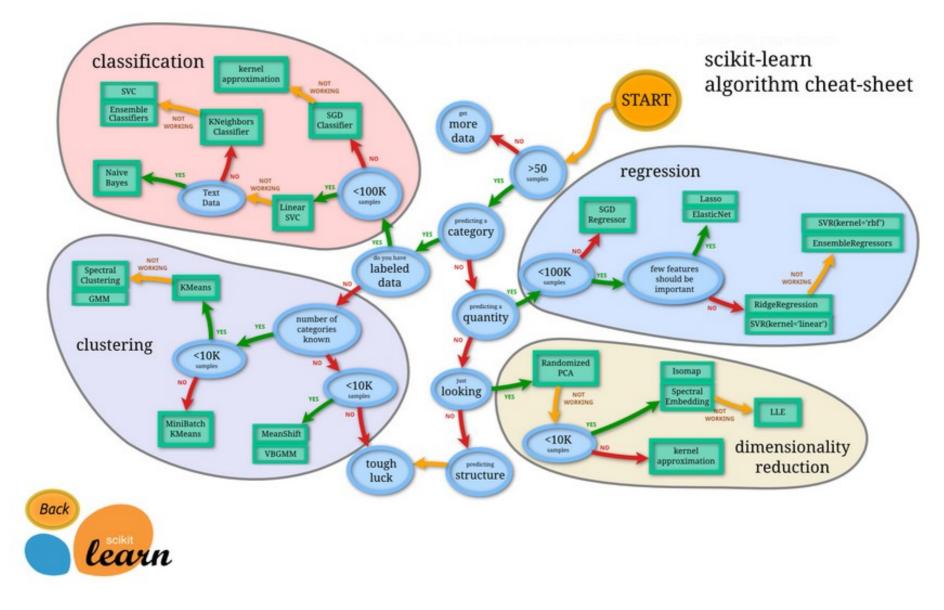
H	T.	)=	0.94
11	Llower	<i>,</i> —	0.57

טו	11	12	13	14	ıo	Labei
3	697.4	31.8	0.83	9.8	852.0	В
9	122.5	7.5	0.91	111.5	756.4	В
18	211.2	28.0	0.04	124.2	462.5	Α
12	498.2	33.3	0.81	125.7	512.2	В
19	409.0	25.6	0.20	144.1	990.3	В
2	366.4	28.9	0.99	153.7	348.5	Α
5	482.9	22.1	0.31	159.9	1106.9	В
4	521.8	36.1	0.87	343.9	1195.2	Α
15	153.3	1.6	0.58	502.2	65.2	Α
13	683.6	11.9	0.56	608.2	1640.3	В
11	761.8	2.4	0.62	658.3	11.0	В
6	510.8	7.1	0.05	663.1	58.7	В
14	481.7	4.1	0.95	756.6	253.8	Α
1	354.1	15.0	0.73	802.3	347.0	В

ID	f1	f2	f3	f4	f5	Label
10	357.6	16.2	0.28	815.9	664.4	Α
8	275.1	36.2	0.12	841.7	409.4	Α
7	710.0	38.4	0.52	861.4	812.9	Α
17	396.6	38.7	0.72	886.1	1203.5	Α
16	399.6	37.2	0.94	894.0	741.4	Α
20	277.5	14.8	0.83	935.4	103.4	Α

$$H(T_{upper})=0$$

### Ideen für weitere ML Ansätze: Das ML algorithm cheat sheet



Quelle:https://scikit-learn.org/stable/tutorial/machine\_learning\_map/index.html

#### Aufbau

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

### Das ML Modell zur Vorhersage anwenden

Vorhersage aller Fälle in dem Testdatensatz

# Labels für den Testdatensatz vorhersagen
predictions = model.predict(X\_test)

Wichtig: Der Testdatensatz muss genau so wie der Trainingsdatensatz vorverarbeitet worden sein

# Von Kaggle benutztes Format für die Einsendung der Vorhersagen

	A	В	С
1	PassengerId	Survived	
2	892	0	
3	893	1	
4	894	0	
5	895	0	
6	896	1	
7	897	0	
8	898	1	
9	899	0	
10	900	1	
11	901	0	
12	902	0	
13	903	0	
14	904	1	
15	905	0	
16	906	1	
17	907	1	
18	908	0	
19	909	0	

### Erzeugen der CSV-Datei für die Vorhersagen

DataFrame mit den zwei Spalten Passengerld und Survived

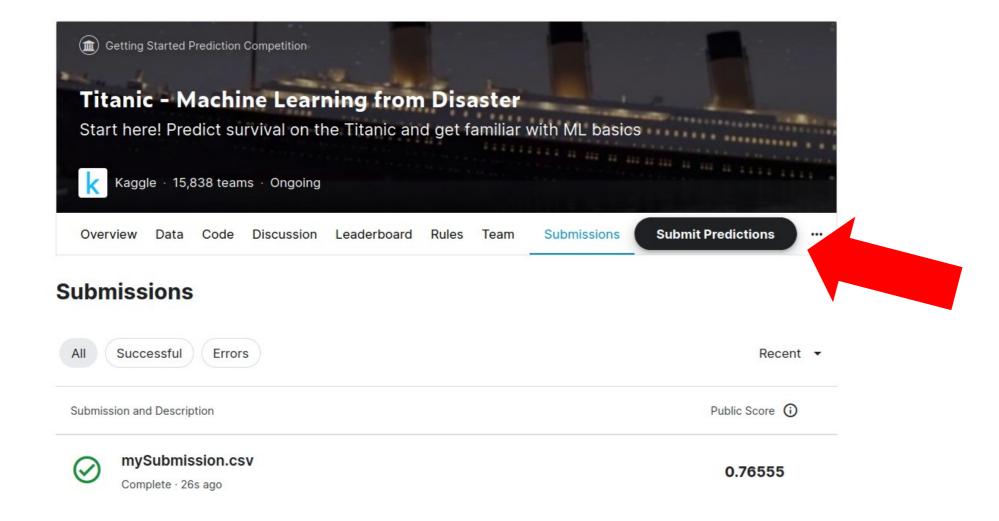
```
# Erzeugen der CSV-Datei mit den Vorhersagen des Modells

output = pd.DataFrame({'PassengerId': test_data.PassengerId, 'Survived': predictions})

output.to_csv('data/submission.csv', index=False)
```

Schreiben des DataFrame in eine CSV-Datei

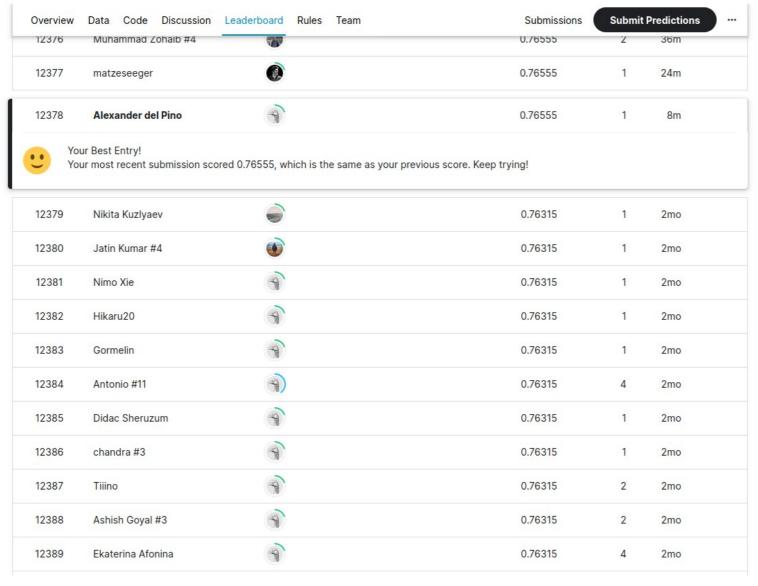
## Einreichen der Lösung in den Kaggle-Wettbewerb



Bildquelle:https://www.kaggle.com/competitions/titanic/submissions

HOCHSCHULE DARMSTADT

# Überprüfen der eigenen Position im Kaggle Leaderboard



Bildquelle:https://www.kaggle.com/competitions/titanic/leaderboard#user\_row

#### Aufbau

- Überblick
- ML Anwendungen
- Kategorien von ML Aufgaben
- Beispiel: Klassifikation der Überlebenden der Titanic
- Kaggle
- Analysieren von Datensätzen
- Datensätze laden
- Datensätze vorverarbeiten
- ML Training
- ML Modell zur Vorhersage anwenden
- Mini-Test

# Mini-Test "ML Klassifikation" – Fällig am (siehe Moodle)

- Was ist ML?
- Wann soll man ML benutzen, wann nicht?
- Nennen Sie ML Anwendungen
- Erklären Sie die ML Kategorie "Supervised Learning"
- Erklären Sie die ML Aufgabe Klassifikation
- Was ist Kaggle?
- Warum ist es wichtig, einen Datensatz zu analysieren?
- Warum ist die Vorverarbeitung wichtig? Nennen Sie hierzu Beispiele
- Was ist ML Training?
- Wie baut man einen Entscheidungsbaum auf?
- Wie sagt man neue Fälle vor?